



INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

ESCOM

Analítica y Visualización de Datos

Análisis y Visualización de Recetas de Cerveza Artesanal

Integrantes:

Galindo Espinosa Ana Lilia
Herrera Moreno Sayuri

Grupo: 5AM1

Profesor(a): Alejandro López Gómez

21 de junio de 2026

Índice

1. Introducción	2
2. Objetivos	2
3. Descripción del conjunto de datos	3
4. Metodología	3
4.1. Selección y preprocesamiento de datos	4
4.2. Medidas de similitud (distancia euclidiana)	4
4.3. Correlación de Pearson	5
4.4. Prueba Chi-cuadrada	5
4.5. Análisis de Componentes Principales (PCA)	5
4.6. Dashboard	5
5. Resultados	5
5.1. Distribución de las variables	5
5.2. Similitud entre estilos	6
5.3. Correlación entre variables	7
5.4. Prueba Chi-cuadrada	8
5.5. Análisis de Componentes Principales (PCA)	8
5.6. Dashboard	9
6. Conclusiones	12

1. Introducción

La cerveza artesanal se elabora siguiendo recetas muy distintas entre sí: algunas son suaves y ligeras, algunas otras son fuertes, oscuras o demasiado amargas. Cada receta se puede describir con un conjunto de características numéricas, como su cantidad de alcohol, su nivel de amargor o su color. Al día de hoy hay muchas recetas disponibles en internet, tal cual es el caso del dataset de **Brewer's Friend** es una comunidad de cerveceros que comparten información sobre sus recetas como las que se encuentran en Kaggle, el cual contiene información sobre miles de recetas de cerveza artesanal, estilos y métodos de elaboración.

El conjunto de datos utilizado en este análisis reúne más de **73,000 recetas** de cerveza, cada una con varias de estas características. El problema es que, al tener tantos registros y tantas variables, resulta muy difícil entender la información a simple vista. No es fácil saber, por ejemplo, qué estilos de cerveza se parecen entre sí, qué características están relacionadas (como el alcohol y el azúcar), o si el estilo de una cerveza tiene que ver con la forma en que se elabora. Además, como los datos fueron capturados por muchas personas distintas, contienen errores, valores faltantes y valores fuera de lo normal que deben corregirse antes de analizarlos.

Por esta razón, en este proyecto se realiza un proceso de limpieza y análisis de los datos para encontrar patrones y relaciones entre las recetas. Se aplican distintas técnicas para medir qué tan parecidas son las cervezas entre sí, para identificar qué características se relacionan, para comprobar si el estilo depende del método de elaboración y para resumir la información en pocas variables que faciliten su visualización. Finalmente, los resultados se presentan en un **tablero interactivo (dashboard)** que permite explorar la información de forma sencilla.

La descripción detallada del conjunto de datos y el diccionario de variables se presentan en la siguiente sección.

2. Objetivos

Objetivo general

Analizar y visualizar las características fisicoquímicas de recetas de cerveza artesanal para identificar patrones, relaciones y agrupamientos entre estilos y métodos de elaboración.

Objetivos específicos

- **Realizar el preprocesamiento y limpieza del conjunto de datos:** corregir los errores presentes en la información, tratar los valores faltantes, eliminar los valores fuera de lo normal y dejar los datos en una escala comparable, de modo que el análisis posterior sea confiable.
- **Analizar la distribución de las variables fisicoquímicas:** observar cómo se comportan variables como el alcohol, el amargor o el color, identificando sus valores más frecuentes y su rango.
- **Calcular medidas de similitud entre recetas mediante la distancia euclidiana:** determinar qué tan parecidos son los estilos de cerveza a partir de sus características, para reconocer cuáles se asemejan más entre sí.
- **Evaluar la correlación entre variables utilizando el coeficiente de Pearson:** medir si dos características aumentan o disminuyen juntas, por ejemplo, si una mayor cantidad de azúcar inicial se relaciona con más alcohol.

- **Determinar la dependencia entre variables categóricas mediante la prueba Chi-cuadrada:** comprobar si el estilo de la cerveza está relacionado con el método con el que se elabora, o si son independientes.
- **Aplicar el Análisis de Componentes Principales (PCA):** resumir varias variables en unas pocas que conserven la mayor parte de la información, para poder visualizar los datos de forma más simple y observar si los estilos forman grupos.
- **Desarrollar un dashboard interactivo:** construir una herramienta visual que permita explorar la información y los resultados del análisis de manera sencilla, sin necesidad de programar.

3. Descripción del conjunto de datos

El conjunto de datos utilizado proviene de la comunidad **Brewer's Friend** y está disponible en la plataforma Kaggle. Contiene **73,861 recetas** de cerveza artesanal descritas mediante **23 columnas**. Cada fila corresponde a una receta y cada columna a una característica de la cerveza, ya sea numérica (como el alcohol, el amargor o el color) o categórica (como el estilo o el método de elaboración).

Dado que la información fue capturada por muchos usuarios distintos, el conjunto presenta valores faltantes en varias columnas, así como algunos valores fuera de lo normal que corresponden a errores de captura. Por ello, para este trabajo se seleccionaron únicamente las variables más relevantes para el análisis fisicoquímico. En la Tabla 1 se presenta el diccionario de datos con el significado de cada variable utilizada.

Tabla 1: Diccionario de datos: variables utilizadas en el análisis.

Variable	Significado	Unidad
ABV	Cantidad de alcohol de la cerveza	%
IBU	Nivel de amargor (aportado por el lúpulo)	escala IBU
Color	Qué tan oscura es la cerveza	escala SRM
OG	Densidad antes de fermentar (azúcar inicial)	gravedad específica
FG	Densidad después de fermentar (azúcar restante)	gravedad específica
Efficiency	Eficiencia del proceso de elaboración	%
Style	Estilo de la cerveza (IPA, Lager, etc.)	categórica
BrewMethod	Método con el que se elaboró	categórica

4. Metodología

Para el desarrollo de este proyecto se siguió la metodología **KDD** (*Knowledge Discovery in Databases*, o Descubrimiento de Conocimiento en Bases de Datos), la cual consiste en un proceso estructurado para extraer información útil a partir de grandes volúmenes de datos. Esta metodología se compone de las siguientes etapas:

1. **Selección:** se elige el conjunto de datos y las variables relevantes para el análisis.
2. **Preprocesamiento:** se limpian los datos, tratando valores faltantes y valores atípicos.

3. **Transformación:** se preparan los datos para el análisis, por ejemplo escalándolos a una misma medida.
4. **Minería de datos:** se aplican las técnicas de análisis para encontrar patrones y relaciones.
5. **Interpretación y evaluación:** se interpretan los resultados obtenidos para convertirlos en conocimiento.

En este trabajo se aplicó el proceso KDD **hasta la etapa de análisis de datos**, ya que el objetivo es comprender, describir y visualizar la información, y no construir un modelo de predicción. A continuación se describe cada etapa realizada.

4.1. Selección y preprocesamiento de datos

Selección. Del conjunto original de 23 columnas se descartaron aquellas que solo funcionan como identificadores y no aportan información sobre las características de la cerveza, como la dirección web de la receta (URL) y el identificador de usuario (UserId). También se omitieron columnas con una gran cantidad de valores faltantes. De esta manera, se conservaron las variables fisicoquímicas de interés (ABV, IBU, Color, OG, FG y Efficiency) junto con las variables categóricas Style y BrewMethod.

Limpieza. Se eliminaron los registros duplicados. Posteriormente se revisaron los valores faltantes en las variables seleccionadas; como estas no presentaban datos ausentes, no fue necesario aplicar ninguna técnica de imputación.

Para los valores atípicos (valores fuera de lo normal, generalmente errores de captura) se utilizó el **método del rango intercuartílico (IQR)**. Este método considera atípico cualquier valor que quede por debajo de $Q_1 - 1,5 \cdot IQR$ o por encima de $Q_3 + 1,5 \cdot IQR$, donde Q_1 y Q_3 son el primer y tercer cuartil. Gracias a este filtrado, el conjunto de datos pasó de **73,861 a 49,217 recetas**, eliminando valores claramente erróneos (por ejemplo, niveles de amargor imposibles para una cerveza real).

Transformación. Finalmente, las variables se **estandarizaron** con *StandardScaler*, dejándolas con media cero y desviación estándar uno. Este paso es necesario porque las variables están en escalas muy distintas (por ejemplo, el IBU toma valores de varias decenas mientras que la densidad ronda 1.0); sin estandarizar, las variables de mayor magnitud dominarían los cálculos de distancia y el análisis de componentes principales.

Una vez preparados los datos, se realizó la etapa de **análisis de datos**, en la que se aplicaron las siguientes técnicas.

4.2. Medidas de similitud (distancia euclidiana)

Para identificar qué estilos de cerveza se parecen más entre sí, se calculó la **distancia euclidiana**. Esta distancia mide qué tan separados están dos puntos: a menor distancia, mayor parecido. Como cada estilo tiene muchas recetas, primero se obtuvo el **promedio de cada variable por estilo** (un perfil representativo de cada estilo) usando los datos ya estandarizados. El análisis se limitó a los **15 estilos más frecuentes**, ya que los estilos con muy pocas recetas no son representativos y dificultan la lectura del resultado. Con estos perfiles se construyó una matriz de distancias, que se representó mediante un mapa de calor (*heatmap*).

4.3. Correlación de Pearson

Para conocer la relación entre las variables numéricas se utilizó el **coeficiente de correlación de Pearson**, que toma valores entre -1 y 1 . Un valor cercano a 1 indica que dos variables aumentan juntas, uno cercano a -1 que cuando una sube la otra baja, y un valor cercano a 0 que no existe una relación lineal. Se calcularon especialmente las relaciones entre el alcohol y el amargor (ABV-IBU), el alcohol y la densidad inicial (ABV-OG) y el amargor y el color (IBU-Color).

4.4. Prueba Chi-cuadrada

Para comprobar si el estilo de la cerveza depende del método con el que se elabora se aplicó la **prueba Chi-cuadrada**, que sirve para analizar la relación entre dos variables categóricas. Se construyó una tabla de contingencia entre el estilo (*Style*) y el método (*BrewMethod*). Debido a que existen muchos estilos distintos, se agruparon en los **10 más frecuentes** más una categoría “Otros”, con el fin de cumplir el supuesto de la prueba, que requiere que las frecuencias esperadas en cada celda sean suficientes (mayores o iguales a 5).

4.5. Análisis de Componentes Principales (PCA)

Para resumir la información se utilizó el **Análisis de Componentes Principales (PCA)**, una técnica que combina las variables originales en unas pocas variables nuevas, llamadas componentes, que conservan la mayor parte de la información. Se aplicó PCA sobre las seis variables fisicoquímicas estandarizadas para reducirlas a **dos componentes**, lo que permite representar las recetas en una gráfica de dos dimensiones y observar si los estilos forman grupos.

4.6. Dashboard

Finalmente, para facilitar la exploración de los datos se desarrolló un **dashboard interactivo** utilizando las herramientas *Streamlit* y *Plotly*. El dashboard cuenta con filtros (por estilo, método y rangos de alcohol y amargor) que actualizan todas las gráficas de forma automática, así como indicadores resumen y varias pestañas que organizan la información en distribución de estilos, histogramas, relaciones entre variables y una tabla de datos.

5. Resultados

5.1. Distribución de las variables

En primer lugar se analizó cómo se distribuyen las recetas según sus estilos y sus características. La Figura 1 muestra los estilos con mayor número de recetas, donde destacan claramente las variantes de cerveza tipo *American IPA* y *American Pale Ale*. Por su parte, las Figuras 2 y 2 presentan la distribución del alcohol (ABV) y del amargor (IBU), respectivamente; en ambos casos la mayoría de las recetas se concentra en valores bajos a moderados.




Figura 1: Estilos de cerveza más frecuentes en el conjunto de datos.




Figura 2: Distribución del alcohol (ABV) y del amargor (IBU).

5.2. Similitud entre estilos

A partir de la matriz de distancias euclidianas (Figura 3) se observa que los estilos más parecidos entre sí son **Blonde Ale** y **Kölsch** (distancia $\approx 0,17$), junto con las cervezas de trigo (*Weizen*, *Witbier*, *Weissbier*). Todas ellas son cervezas claras, suaves y de bajo amargor. En cambio, el estilo más distinto del resto fue la **American Brown Ale** (distancia $\approx 3,0$ frente a las claras), lo cual es coherente con su mayor color y cuerpo.




Figura 3: Matriz de distancias euclidianas entre los 15 estilos más frecuentes. Los tonos más oscuros indican mayor parecido.

5.3. Correlación entre variables

La Figura 4 muestra la matriz de correlación de Pearson. Los resultados más relevantes son:

- **ABV–OG:** $r = 0,95$, una correlación muy fuerte y positiva. Es coherente, ya que el azúcar inicial (OG) es lo que se convierte en alcohol al fermentar.
- **ABV–IBU:** $r = 0,37$, una relación positiva débil: las cervezas más fuertes tienden a ser ligeramente más amargas.
- **IBU–Color:** $r = 0,02$, prácticamente nula: el amargor y el color no están relacionados.




Figura 4: Matriz de correlación de Pearson entre las variables fisicoquímicas.

5.4. Prueba Chi-cuadrada

La prueba Chi-cuadrada entre el estilo y el método de elaboración arrojó un estadístico $\chi^2 = 74,17$ con un **valor** $p = 1,3 \times 10^{-5}$, menor a 0,05. Por lo tanto, se rechaza la hipótesis de independencia y se concluye que **sí existe dependencia** entre el estilo de la cerveza y el método de elaboración. Además, el 0 % de las celdas presentó una frecuencia esperada menor a 5, por lo que se cumple el supuesto de la prueba y el resultado es confiable.

5.5. Análisis de Componentes Principales (PCA)

Las dos primeras componentes principales explican en conjunto el **61 % de la varianza** (PC1: 43.8 %, PC2: 17.2 %). La primera componente (PC1) representa la *fuerza o cuerpo* de la cerveza (alcohol, densidades), mientras que la segunda (PC2) contrapone el *color* frente al *amargor*. La variable Efficiency no resultó relevante. Como se aprecia en la Figura 5, los estilos forman **grupos parcialmente identificables**: las cervezas oscuras (como la *American Brown Ale*) se ubican en la parte superior, mientras que las claras y amargas (como la *American IPA*) se sitúan en la parte inferior, lo que coincide con el análisis de similitud.




Figura 5: Representación de las recetas en las dos primeras componentes principales, coloreadas por estilo.

5.6. Dashboard

Como resultado final se construyó un **dashboard interactivo** con las herramientas *Streamlit* (para la interfaz) y *Plotly* (para las gráficas). El dashboard lee el conjunto de datos ya limpio y permite explorar la información sin necesidad de programar. Cuenta con una barra lateral de **filtros** (estilo, método de elaboración y rangos de alcohol y amargor) que actualizan todas las gráficas de forma automática, una fila de **indicadores resumen** (número de recetas, estilos, ABV e IBU promedio) y la información organizada en **pestañas**. A continuación se describe cada una de sus secciones.

1. Vista general y resumen. Al abrir el dashboard se muestran los filtros, los indicadores resumen y la pestaña *Resumen*, que presenta la distribución de los estilos de cerveza y los estilos más frecuentes de la selección actual (Figura 6).



Figura 6: Vista general: filtros, indicadores resumen y distribución de estilos.

2. Distribuciones. La pestaña *Distribuciones* muestra los histogramas del alcohol (ABV) y del amargor (IBU), que permiten observar en qué rangos se concentran la mayoría de las recetas (Figura 7).



Figura 7: Pestaña de distribuciones: histogramas de ABV e IBU.

3. Relaciones. La pestaña *Relaciones* permite comparar variables mediante un diagrama de dispersión (en el que el usuario elige los ejes), además de mostrar la proyección del PCA y la matriz de correlación (Figura 8).




Figura 8: Pestaña de relaciones: dispersión entre variables, PCA y correlación.

4. **Datos.** La pestaña *Datos* contiene un explorador de la tabla con un buscador por estilo, que permite consultar las recetas individuales que cumplen los filtros aplicados (Figura 9).




Figura 9: Pestaña de datos: explorador de la tabla con buscador.

5. **Diccionario de datos.** Por último, el dashboard incluye un panel desplegable con el diccionario de datos, disponible en todo momento, que explica el significado de cada variable (Figura 10).




Figura 10: Diccionario de datos integrado en el dashboard.

6. Conclusiones

A lo largo de este proyecto se aplicó la metodología KDD, desde la limpieza de los datos hasta su análisis y visualización, sobre un conjunto de más de 73,000 recetas de cerveza artesanal. El preprocesamiento permitió eliminar errores y valores atípicos, reduciendo el conjunto a 49,217 recetas confiables y comparables entre sí.

Un aspecto importante es que los distintos análisis realizados son coherentes, lo que da consistencia a los resultados. El análisis de similitud mostró que las cervezas claras y suaves (como la Blonde Ale y la Kölsch) se parecen mucho entre sí, mientras que las cervezas oscuras y con más cuerpo (como la American Brown Ale) se separan del resto. Esta misma agrupación se confirmó con el PCA, donde los estilos forman grupos parcialmente identificables según su color, cuerpo y amargor.

En cuanto a las relaciones entre variables, la correlación de Pearson reveló que el alcohol depende casi por completo del azúcar inicial (ABV-OG, $r = 0.95$), mientras que el amargor y el color resultaron independientes. Por su parte, la prueba Chi-cuadrada confirmó que el estilo de la cerveza está relacionado con el método de elaboración.

Finalmente, el dashboard interactivo permitió reunir todos estos hallazgos en una sola herramienta visual, facilitando la exploración de los datos sin necesidad de programar. En conjunto, este proyecto demuestra cómo aplicar técnicas de análisis de datos para extraer conocimiento de un conjunto complejo, y cómo presentarlo de forma clara e interactiva.

Referencias

- Trofe, J. *Beer Recipes Dataset* (Brewer's Friend). Kaggle. <https://www.kaggle.com/datasets/jtrofe/beer-recipes>
- Documentación de las bibliotecas *pandas*, *scikit-learn*, *SciPy*, *Plotly* y *Streamlit*.